

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA KHOA HỌC MÁY TÍNH

HỌC PHẦN: PHÂN TÍCH KHAI PHÁ DỮ LIỆU LỚN



BÁO CÁO BÀI TẬP LỚN NHÓM 9

**ĐỀ TÀI : HỆ THỐNG PHÁT HIỆN TƯƠNG ĐỒNG VĂN BẢN
TRÊN TẬP DỮ LIỆU BÀI BÁO KHOA HỌC**

Họ và tên

Mã sinh viên

Nguyễn Trường Giang

B22DCKH034

Phạm Quốc Anh

B22DCKH006

Trương Quốc Bình

B22DCKH008

Giảng viên hướng dẫn: GV. Đặng Hoàng Long

Hà Nội - 2025

MỤC LỤC

CHƯƠNG 1: GIỚI THIỆU DỰ ÁN VÀ BỘ DỮ LIỆU	3
1. TỔNG QUAN DỰ ÁN	3
2. PHẠM VI DỮ LIỆU VÀ HẠ TẦNG KỸ THUẬT	5
CHƯƠNG 2: KIẾN TRÚC HỒ DỮ LIỆU (MEDALLION ARCHITECTURE).....	7
3. THU THẬP VÀ XỬ LÝ DỮ LIỆU NGOẠI TUYẾN	10
4. QUY TRÌNH XỬ LÝ VÀ LÀM SẠCH VĂN BẢN ĐA TẦNG	14
5. XÂY DỰNG BỘ DỮ LIỆU SILVER+ VÀ GOLD LOOKUP.....	17
CHƯƠNG 3: CÁC KỸ THUẬT VÀ GIẢI THUẬT PHÁT HIỆN TƯƠNG ĐỒNG ..	19
6. HỆ THỐNG MINHASH LSH (LỘC THÔ VÀ PHÁT HIỆN ỨNG VIÊN)	19
7. HỆ THỐNG ĐỐI SOÁT PASSAGE-LEVEL (EXACT / N-GRAM / FUZZY MATCHING)	21
8. CITATION & EXCLUSION CHECK.....	27
9. ENGINE PHÁT HIỆN TƯƠNG ĐỒNG TRỰC TUYẾN (ONLINE RETRIEVAL).....	34
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ KỸ THUẬT	37
Kịch bản thực nghiệm hệ thống.....	37
Định lượng và Đánh giá hiệu năng hệ thống.....	38
Phân tích sâu và Phản biện giải thuật kỹ thuật	39
Hạn chế hiện tại và Định hướng phát triển tối ưu	40

CHƯƠNG 1: GIỚI THIỆU DỰ ÁN VÀ BỘ DỮ LIỆU

1. TỔNG QUAN DỰ ÁN

1.1. Mục tiêu hệ thống

Dự án hướng tới xây dựng một hệ thống phát hiện tương đồng học thuật trên tập dữ liệu ArXiv quy mô lớn. Khác với cách tiếp cận đưa ra “phán quyết đạo văn” tuyệt đối mang tính chủ quan, hệ thống không tự động kết luận một tài liệu là đạo văn. Thay vào đó, hệ thống sinh ra Báo cáo Tương đồng (Similarity Report) toàn diện để hỗ trợ chuyên gia thẩm định và người chấm điểm đánh giá chi tiết các đoạn văn bản trùng lặp, nguồn đối chiếu tương ứng, mức độ tương đồng cụ thể, trạng thái trích dẫn và các trường hợp được loại trừ hợp lệ theo ngữ cảnh.

Quy trình xử lý cốt lõi của hệ thống bao gồm: tiếp nhận một tài liệu PDF đầu vào, thực hiện trích xuất toàn bộ văn bản thô, tiến hành quy trình làm sạch sâu, chia nhỏ văn bản thành các phân đoạn, khởi tạo chữ ký số học MinHash signature, thực hiện truy vấn LSH index để xác định nhanh danh sách các bài báo khoa học nghi vấn, và cuối cùng nạp dữ liệu nguồn từ tầng Gold lookup đã được tối ưu hóa cho các thao tác truy vấn trực tuyến (online query).

Các phân đoạn nghi vấn sau đó sẽ được đưa vào bộ kiểm tra chi tiết thông qua ba kỹ thuật: Exact Matching, N-gram Overlap và Fuzzy Matching. Bước cuối cùng trong luồng xử lý là áp dụng bộ lọc Citation & Exclusion Check nhằm tự động loại trừ phần tài liệu tham khảo (References), các đoạn trích dẫn nguyên văn hợp lệ nằm trong dấu ngoặc kép, các trùng khớp ngắn (small matches) hoặc các thành phần siêu dữ liệu biểu mẫu hệ thống (metadata/boilerplate).

Mục tiêu cuối cùng là thiết lập một báo cáo tương đồng chi tiết bao gồm các chỉ số định lượng: Tỷ lệ tương đồng tổng thể (Overall Similarity), Mức độ rủi ro hệ thống (Risk Level), danh sách các nguồn trùng khớp, tỷ lệ đóng góp (contribution) theo từng nguồn, các phân đoạn tương đồng trực quan (matched passages), trạng thái trích dẫn cụ thể và các lý do loại trừ tương ứng.

1.2. Phân loại các cấp độ tương đồng cú pháp và đạo văn

Hành vi đạo văn học thuật được định nghĩa là việc người viết sử dụng nội dung, phương thức diễn đạt, dữ liệu thực nghiệm, phương pháp luận, ý tưởng khoa học hoặc kết quả nghiên cứu của tác giả khác mà không thực hiện ghi nhận nguồn gốc một cách phù

hợp. Trong phạm vi phiên bản hiện tại, hệ thống tập trung tối ưu vào việc phát hiện các hành vi sao chép nguyên văn, chỉnh sửa cấu trúc nhẹ, trùng lặp n-gram và các đoạn văn bản tương đồng cao. Các mức độ paraphrase ngữ nghĩa sâu và đạo văn ý tưởng được xác định là hướng tiếp cận mở rộng trong tương lai.

Cấp độ	Hình thức	Đặc điểm kỹ thuật	Giải pháp đối soát trong hệ thống
1	Copy nguyên văn (Verbatim)	Xuất hiện nhiều cụm 5-gram trùng khớp tuyệt đối, chỉ số Jaccard bề mặt rất cao, Exact Matching đạt điểm tối đa.	Tích hợp bộ băm MinHash LSH + Giải thuật Exact Matching + N-gram Overlap
2	Sửa đổi nhỏ / thay từ cục bộ	Cấu trúc câu tương đồng, xuất hiện sai khác nhỏ về mặt ký tự hoặc thay thế từ nối rải rác.	Giải thuật N-gram Overlap + Thuật toán Fuzzy Matching
3	Paraphrase cấu trúc câu	Cú pháp và trật tự từ thay đổi mạnh mẽ, mật độ n-gram trùng	Hướng nghiên cứu mở rộng: Sử dụng phương pháp Semantic

Cấp độ	Hình thức	Đặc điểm kỹ thuật	Giải pháp đối soát trong hệ thống
		khớp bề mặt giảm sâu.	Retrieval làm tín hiệu hỗ trợ độc lập.
4	Đạo văn ý tưởng	Không trùng khớp từ ngữ bề mặt, nhưng vay mượn hoàn toàn phương pháp luận, chuỗi thí nghiệm hoặc hệ thống lập luận.	Triển khai phân tích ngữ cảnh nâng cao (Concept/Citation analysis) kết hợp với đánh giá từ hội đồng chuyên gia.

2. PHẠM VI DỮ LIỆU VÀ HẠ TẦNG KỸ THUẬT

Hệ thống được thiết kế và triển khai dựa trên các nền tảng hạ tầng tính toán phân tán và lưu trữ đám mây hiện đại để đáp ứng quy mô dữ liệu lớn của kho học thuật ArXiv.

Thành phần cấu trúc	Chi tiết cấu hình và phạm vi triển khai
Nguồn dữ liệu học thuật	Toàn bộ siêu dữ liệu (Metadata) và tệp tin PDF gốc của các bài báo khoa học từ nguồn ArXiv.

Thành phần cấu trúc	Chi tiết cấu hình và phạm vi triển khai
Kích thước tập dữ liệu nghiên cứu	Xấp xỉ 4GB dữ liệu siêu dữ liệu định dạng JSONL và khoảng 438GB khối lượng tệp định dạng PDF.
Số lượng tài liệu thực nghiệm	Vượt ngưỡng 300.000 bài báo khoa học trong phạm vi thiết lập kịch bản thực nghiệm của nhóm.
Ngôn ngữ tài liệu học thuật	Tiếng Anh tiêu chuẩn khoa học.
Lĩnh vực chuyên ngành nghiên cứu	Khoa học máy tính (CS), Vật lý (Physics), Toán học (Math), Sinh học (Biology), Kinh tế học (Economics)...
Hạ tầng lưu trữ phân tán	Sử dụng giải pháp Google Cloud Storage thông qua bucket lưu trữ chuyên dụng.
Nền tảng xử lý tính toán ngoại tuyến	Sử dụng môi trường Google Colab phối hợp với hệ thống Dataproc Cluster và các cấu hình VM instance.

Thành phần cấu trúc	Chi tiết cấu hình và phạm vi triển khai
Nền tảng truy vấn trực tuyến	Môi trường máy cục bộ hoặc notebook kết hợp cơ chế nạp trước LSH index và tối ưu hóa phân vùng lookup partition theo ứng viên.

CHƯƠNG 2: KIẾN TRÚC HỒ DỮ LIỆU (MEDALLION ARCHITECTURE)

Hệ thống áp dụng mô hình kiến trúc kiến trúc dữ liệu phân tầng Data Lake 3 lớp nhằm đảm bảo tối đa khả năng truy vết nguồn gốc, khả năng tái xử lý dữ liệu hàng loạt và hiệu quả thực thi tối ưu của các thuật toán tra cứu trực tuyến.

Tầng dữ liệu	Đường dẫn lưu trữ trên hệ thống	Nội dung cấu trúc chi tiết	Định dạng lưu trữ
Bronze (Raw)	bronze/	Tập hợp toàn bộ các nguồn dữ liệu thô nguyên bản thu thập trực tiếp.	JSONL, PDF Binary
Bronze - Siêu dữ	bronze/raw_met	Siêu dữ liệu học	JSONL Flat

Tầng dữ liệu	Đường dẫn lưu trữ trên hệ thống	Nội dung cấu trúc chi tiết	Định dạng lưu trữ
liệu	adata/arxiv/	thuật đã qua chuẩn hóa cấu trúc phẳng từ nguồn Kaggle.	
Bronze - Tài liệu gốc	bronze/raw_pdf/arxiv/	Các tệp tin khoa học PDF nguyên bản được thu thập tự động từ hệ thống arxiv.org.	PDF Binary
Silver - Văn bản thô	silver/arxiv_text_parquet/	Toàn bộ nội dung văn bản thô sau khi được giải mã và trích xuất từ tệp PDF gốc.	Parquet
Silver - Khử nhiễu	silver/arxiv_cleaned_parquet/	Văn bản học thuật hoàn chỉnh sau khi trải qua quy trình tiền xử lý 9 tầng tuần tự.	Parquet

Tầng dữ liệu	Đường dẫn lưu trữ trên hệ thống	Nội dung cấu trúc chi tiết	Định dạng lưu trữ
Silver+ Unified Dataset	silver/arxiv_silver_plus/	Bộ dữ liệu hợp nhất hoàn chỉnh từ các thao tác liên kết văn bản sạch và siêu dữ liệu học thuật.	PySpark Parquet
Gold - Chữ ký băm	gold/minhash_signatures/	Tập hợp các vectơ mã hóa MinHash signatures tương ứng với cấu hình 128 hoán vị toán học.	Parquet
Gold - Chỉ mục LSH	gold/minhash_index/	Cấu trúc cây chỉ mục phục vụ tìm kiếm ứng viên nhanh LSH Index kết hợp các thực thể MinHash.	Pickle Object
Gold - Tra cứu trực tuyến	gold/online_paper_lookup/	Bảng dữ liệu tối ưu hóa tra cứu	Partitioned Parquet

Tầng dữ liệu	Đường dẫn lưu trữ trên hệ thống	Nội dung cấu trúc chi tiết	Định dạng lưu trữ
		theo mã tài liệu ứng viên, áp dụng chiến lược phân vùng tiền tố phục vụ phản hồi nhanh.	
Gold - Báo cáo kết quả	data/reports/	Đầu ra hoàn chỉnh Báo cáo Tương đồng đa dạng định dạng cấu trúc trực quan hóa dữ liệu.	JSON, HTML, DOCX

3. THU THẬP VÀ XỬ LÝ DỮ LIỆU NGOẠI TUYẾN

3.1. Giai đoạn 1: Thu thập & Chuẩn hóa Siêu dữ liệu (Bronze Metadata)

Hệ thống thu thập dữ liệu siêu dữ liệu từ nguồn chính thức, áp dụng cơ chế xử lý luồng (Stream Processing) liên tục theo từng dòng văn bản độc lập nhằm chuyển hóa cấu trúc lồng phức tạp thành cấu trúc phẳng JSON Flat đồng bộ, trước khi đẩy thẳng vào không gian lưu trữ Bronze thông qua lệnh đồng bộ hệ thống.

Trường thuộc tính	Kiểu kiểu dữ liệu	Mô tả ý nghĩa ngữ cảnh học thuật
doc_id	String	Mã chuỗi định danh duy nhất cấu trúc hệ thống (mẫu: arxiv_<id>).
hash_sha256	String	Mã băm bảo mật SHA-256 tương ứng với đường dẫn tài liệu trực tuyến nguồn.
title	String	Tiêu đề chính thức của bài báo khoa học (đã xử lý triệt tiêu ký tự ngắt dòng).
abstract	String	Nội dung tóm tắt tóm lược của nghiên cứu khoa học.
authors	Array<String>	Mảng danh sách cấu trúc tên các tác giả nghiên cứu (Định dạng: Firstname Lastname).

Trường thuộc tính	Kiểu kiểu dữ liệu	Mô tả ý nghĩa ngữ cảnh học thuật
categories	Array<String>	Mảng phân loại danh mục học thuật theo chuẩn ArXiv (ví dụ: cs.AI, math.ST).
publish_date	String	Ngày phát hành hoặc mốc thời gian cập nhật phiên bản tài liệu gần nhất.
doi	String	Mã định danh vật thể số (Digital Object Identifier) phục vụ đối chiếu liên kết.
source_url	String	Đường dẫn URL tham chiếu gốc của tài liệu trên hệ thống arxiv.org.
pdf_url	String	Đường dẫn tải trực tiếp luồng dữ liệu nhị phân tệp PDF.

Trường thuộc tính	Kiểu kiểu dữ liệu	Mô tả ý nghĩa ngữ cảnh học thuật
local_path_bronze	String	Đường dẫn logic xác định vị trí tệp tin PDF trong không gian lưu trữ đám mây Bronze.
scraped_at	String (ISO8601)	Mốc dấu thời gian hệ thống thực hiện tiến trình thu thập dữ liệu thành công.

3.2. Giai đoạn 2: Tiến trình thu thập dữ liệu PDF thời gian thực

Tiến trình thu thập tệp tin từ hệ thống máy chủ arxiv.org được thiết kế dựa trên kỹ thuật tải luồng trực tiếp (Streaming Upload) đồng bộ hóa thẳng lên hạ tầng Cloud Storage, tối ưu hóa triệt để tài nguyên ổ đĩa cục bộ. Luồng thu thập được trang bị cấu hình HTTP Session chuyên sâu tích hợp bộ thử lại 5 lần kết hợp thuật toán giãn cách lũy thừa (Exponential Backoff).

Để bảo vệ hệ thống phân phối nội dung nguồn khỏi rủi ro quá tải, một bộ điều phối giới hạn tần suất (Rate Limiting) thiết lập độ trễ ngẫu nhiên từ 1.5 đến 2.5 giây giữa các yêu cầu. Tiến trình tổng thể áp dụng giải pháp phân bổ dải chỉ số mục tiêu độc lập cho phép thực thi tính toán song song đa luồng trên nhiều môi trường điện toán. Tổng kết dữ liệu thực nghiệm ghi nhận khối lượng xử lý thành công đạt 306.404 tệp tin PDF với tổng dung lượng phân tán đạt 438.84 GB dữ liệu.

3.3. Giai đoạn 3: Trích xuất Văn bản từ PDF (Bronze → Silver)

Hệ thống sử dụng nền tảng thư viện PyMuPDF giải mã cấu trúc tài liệu PDF, phối hợp giải pháp xử lý theo lô tối ưu hóa cho quy mô dữ liệu vượt ngưỡng 300GB:

- Cơ chế nạp lô dữ liệu: Tải luân phiên các lô tài liệu xấp xỉ 10.000 tệp tin về không

gian lưu trữ tạm thời cục bộ nhằm ngăn chặn rủi ro tràn dung lượng đĩa cứng.

- Tính toán song song đa xử lý: Sử dụng bộ công cụ ProcessPoolExecutor thực thi song song tiến trình bóc tách văn bản thô nhằm tận dụng tối đa kiến trúc CPU đa nhân của hệ thống.
- Quản lý điểm phục hồi (Checkpoint): Lưu vết tiến trình xử lý chi tiết theo đường dẫn tài liệu thực tế, cho phép hệ thống tự động bỏ qua các tệp tin đã hoàn thành cấu trúc trong kịch bản xảy ra sự cố dừng hệ thống đột ngột.
- Tự động dọn dẹp hệ thống: Kích hoạt lệnh giải phóng bộ nhớ và không gian lưu trữ đĩa cứng tự động ngay khi kết thúc một lô dữ liệu.
- Bộ lọc loại bỏ nhiễu: Áp dụng điều kiện lọc cứng loại bỏ các tài liệu lỗi hoặc tài liệu rác có tổng số lượng từ nhỏ hơn hoặc bằng 10 từ. Đầu ra văn bản thô được ghi nhận dưới định dạng Parquet theo từng cấu trúc lô nhỏ 5.000 tệp tin trực tiếp lên không gian lưu trữ Silver văn bản thô.

4. QUY TRÌNH XỬ LÝ VÀ LÀM SẠCH VĂN BẢN ĐA TẦNG

Tiến trình tiền xử lý văn bản thực hiện bóc tách các thực thể nội dung, chỉ giữ lại các thành phần cốt lõi phục vụ chính xác cho thuật toán đối soát tương đồng cú pháp. Quy trình áp dụng chuỗi liên hoàn 9 tầng xử lý tuần tự độc lập:

Tầng xử lý	Tên công đoạn định nghĩa	Mô tả chi tiết giải thuật thực thi
Tầng 1	ArXiv Header Removal	Sử dụng biểu thức chính quy (Regex) định vị và xóa bỏ toàn bộ chuỗi định danh biểu mẫu chuẩn hóa của hệ thống ArXiv xuất hiện rải rác ở lề văn bản.

Tầng xử lý	Tên công đoạn định nghĩa	Mô tả chi tiết giải thuật thực thi
Tầng 2	Journal Metadata Removal	Nhận diện và triệt tiêu toàn bộ các chuỗi thông tin định dạng mẫu tạp chí khoa học xuất hiện lặp lại cấu trúc hệ thống.
Tầng 3	References Extraction	Thực hiện quét cấu trúc trong phạm vi 40% dung lượng cuối bài báo để định vị chính xác và cắt tách biệt toàn bộ danh mục tài liệu tham khảo, đồng thời bật cờ trạng thái logic chuyên dụng.
Tầng 4	Page Number Removal	Xóa bỏ hoàn toàn hệ thống các ký tự số chỉ định số trang đứng độc lập trong văn bản gốc.
Tầng 5	Ligature Fix	Tự động sửa chữa và chuyển đổi các lỗi dính

Tầng xử lý	Tên công đoạn định nghĩa	Mô tả chi tiết giải thuật thực thi
		chữ Unicode (mẫu: ff, fi, fl, ffi, ffl, st) thành các cụm ký tự chữ cái độc lập tương ứng.
Tầng 6	Unicode Normalization	Áp dụng chuẩn hóa định dạng NFKC thống nhất toàn bộ cấu trúc bảng mã ký tự tương đương về một biểu diễn duy nhất.
Tầng 7	Control Character Removal	Triệt tiêu hoàn toàn hệ thống các ký tự điều khiển hệ thống không có khả năng in ra hiển thị (phạm vi mã hóa ASCII từ 0x00 đến 0x1F và ký tự 0x7F).
Tầng 8	Hyphenation Fix	Tự động phát hiện và nối liền cấu trúc các từ bị phân tách xuống dòng do định dạng căn lề của văn bản gốc

Tầng xử lý	Tên công đoạn định nghĩa	Mô tả chi tiết giải thuật thực thi
		(word-\nword chuyển hóa thành wordword).
Tầng 9	Email/URL/Whitespace	Xóa bỏ toàn bộ địa chỉ thư điện tử, hệ thống liên kết URL; thực hiện chuẩn hóa khoảng trắng và loại bỏ triệt để các dòng trống dư thừa.

Sau giai đoạn làm sạch, hệ thống tự động đánh giá phân loại chất lượng bản ghi thông qua hệ thống cờ hiệu Quality Flag độc lập:

- Trạng thái ok: Tổng số lượng từ sau làm sạch đạt từ 500 từ trở lên đồng thời tỷ lệ duy trì dung lượng văn bản (reduction ratio) đạt từ 0.3 trở lên.
- Trạng thái low_quality: Số lượng từ nằm trong khoảng giới hạn nghiêm ngặt từ 300 từ đến dưới 500 từ.
- Trạng thái empty: Tài liệu thiếu hụt nội dung nghiêm trọng với tổng số từ nhỏ hơn 300 từ.
- Trạng thái over_cleaned: Tỷ lệ giảm dung lượng vượt mức kiểm soát (reduction ratio nhỏ hơn 0.3), cảnh báo rủi ro mất mát thông tin học thuật cốt lõi trong quá trình làm sạch. Dữ liệu sau xử lý hoàn chỉnh được lưu trữ tập trung tại đường dẫn Silver làm sạch văn bản.

5. XÂY DỰNG BỘ DỮ LIỆU SILVER+ VÀ GOLD LOOKUP

Giai đoạn này thực hiện liên kết logic ba luồng dữ liệu độc lập nhằm thiết lập nên bộ dữ liệu tích hợp Silver+ thống nhất, làm cơ sở khoa học vững chắc cho toàn bộ các mô

hình phân tích và thuật toán đối soát tiếp theo.

Nguồn dữ liệu đầu vào	Khóa khóa liên kết chính (Join Key)	Nội dung thuộc tính tích hợp
silver/arxiv_text_parquet/	file_path	Văn bản thô sơ khởi tạo từ tài liệu PDF gốc (raw_text).
silver/arxiv_cleaned_parquet/	file_path (Phương thức Left Join)	Văn bản đã trải qua tiền xử lý khử nhiễu đi kèm cờ phân loại chất lượng hệ thống.
bronze/raw_metadata/	doc_id (Phương thức Left Join)	Tập hợp các siêu dữ liệu cấu trúc: tiêu đề, danh sách tác giả, danh mục phân loại, tóm tắt bài báo.

Hệ thống sử dụng các hàm định nghĩa người dùng PySpark UDF để phân tích cấu trúc bài báo khoa học, tự động bóc tách độc lập ba phần thông tin chính bao gồm: phần mở đầu (introduction), nội dung cốt lõi (body), và toàn bộ văn bản sạch. Bộ dữ liệu tích hợp Silver+ hoàn chỉnh được phân tán dưới dạng Parquet với tổng dung lượng lưu trữ thực tế xấp xỉ 50GB.

Trong quá trình vận hành trực tuyến, việc quét trực tiếp trên dung lượng bộ dữ liệu Silver+ để truy xuất nội dung tài liệu ứng viên gây ảnh hưởng lớn đến thời gian phản hồi của hệ thống. Do đó, một cấu trúc bảng Gold Online Lookup chuyên dụng được thiết lập, áp dụng chiến lược phân vùng dữ liệu theo tiền tố mã hóa tài liệu (\`pid\_prefix\`, bóc tách 4 ký tự đầu tiên của mã tài liệu chuẩn hóa). Cơ chế này cho phép hệ thống trực tuyến thực hiện nạp chính xác phân vùng mục tiêu vào bộ nhớ đệm cục bộ (Local Cache) thay

vì scan toàn bộ kho dữ liệu, tối ưu hóa tốc độ thực thi cho tiến trình đối soát thời gian thực.

CHƯƠNG 3: CÁC KỸ THUẬT VÀ GIẢI THUẬT PHÁT HIỆN TƯƠNG ĐỒNG

6. HỆ THỐNG MINHASH LSH (LỌC THÔ VÀ PHÁT HIỆN ỨNG VIÊN)

Giải pháp bám giữ tính chất tương đồng MinHash kết hợp cấu trúc chỉ mục LSH đóng vai trò lớp lọc thô ứng viên. Mục tiêu cốt lõi của tầng này là chuyển đổi cấu trúc văn bản học thuật dung lượng lớn thành các chữ ký số thu gọn đại diện cho tập hợp cụm từ 5-gram, phục vụ tra cứu nhanh các tài liệu có khả năng trùng khớp cấu trúc cú pháp cao trong không gian dữ liệu lớn, trước khi chuyển giao danh sách ứng viên cho các bộ đối soát phân đoạn chuyên sâu.

Tham số hệ thống	Giá trị thiết lập	Ý nghĩa toán học và lý do lựa chọn cấu hình
SHINGLE_K	5	Thiết lập kích thước cụm từ gồm 5 từ liên tiếp. Giá trị này đảm bảo tính cân bằng tối ưu: ngăn chặn hiện tượng trùng hợp ngẫu nhiên của các từ ngắn (False Positive) đồng thời bắt chính xác các biến đổi nhỏ cấu trúc câu.

Tham số hệ thống	Giá trị thiết lập	Ý nghĩa toán học và lý do lựa chọn cấu hình
NUM_PERM	128	Số lượng các phép biến đổi hoán vị toán học độc lập. Khống chế sai số ước lượng của chỉ số tương đồng Jaccard bề mặt ở mức giới hạn nghiêm ngặt xấp xỉ 8.8%, tối ưu hóa tài nguyên bộ nhớ hệ thống.
LARGE_PRIME	2,147,483,647	Số nguyên tố Mersenne lớn nhất trong giới hạn số nguyên 32-bit, phục vụ làm nền tảng phân phối đồng đều giá trị băm trong giải thuật Universal Hashing.
Hash Function	MD5 mod prime	Chuyển đổi chuỗi cụm từ sang cấu trúc số nguyên phân phối đều, tối đa hóa tốc độ thực thi tính toán so với các thuật toán mã hóa mật

Tham số hệ thống	Giá trị thiết lập	Ý nghĩa toán học và lý do lựa chọn cấu hình
		mã học phức tạp.
Broadcast Params	HASH_A, HASH_B (seed=42)	Cố định tham số gieo hạt ngẫu nhiên hệ thống, thực hiện truyền phát (Broadcast) trên toàn bộ cấu trúc phân tán cluster nhằm đảm bảo tính đồng bộ tuyệt đối giữa tiến trình khởi tạo chỉ mục ngoại tuyến và truy vấn trực tuyến.

7. HỆ THỐNG ĐỐI SOÁT PASSAGE-LEVEL (EXACT / N-GRAM / FUZZY MATCHING)

7.1. Nguyên lý phân đoạn văn bản và đơn vị đối soát

Đơn vị đối soát chính của hệ thống là passage, thường tương ứng với một đoạn văn hoặc một khối câu liên tiếp sau khi văn bản đã được làm sạch. Việc chọn passage thay vì toàn bộ tài liệu giúp giữ lại ngữ cảnh đủ dài để đánh giá tương đồng, đồng thời tránh hiện tượng một đoạn sao chép nhỏ bị che khuất bởi phần lớn nội dung không liên quan của tài liệu.

Một passage quá ngắn dễ tạo ra trùng hợp ngẫu nhiên, đặc biệt với các cụm từ học thuật phổ biến như 'in this paper', 'experimental results show' hoặc 'the proposed method'. Ngược lại, passage quá dài làm giảm độ nhạy vì một thay đổi nhỏ trong cấu trúc đoạn có thể kéo điểm số xuống mạnh. Do đó hệ thống sử dụng bộ tiền lọc độ dài, loại bỏ các phân

đoạn dưới 10 từ và kiểm tra tỷ lệ độ dài giữa hai đoạn trước khi tính điểm chi tiết.

Trong thực nghiệm, passage-level matching được triển khai theo tư duy ưu tiên bằng chứng mạnh trước, bằng chứng yếu sau. Nếu hai đoạn đã trùng tuyệt đối thì không cần tính các chỉ số phức tạp hơn. Nếu không trùng tuyệt đối, hệ thống chuyển sang đánh giá mức độ bao phủ n-gram. Nếu vẫn chưa đủ điều kiện, fuzzy matching được dùng như lớp kiểm tra cuối cùng để phát hiện sai khác ký tự nhỏ hoặc lỗi trích xuất PDF.

7.2. Exact Matching - phát hiện sao chép nguyên văn

Exact Matching là lớp đối soát có độ tin cậy cao nhất. Trước khi so sánh, hai đoạn văn bản được chuẩn hóa về chữ thường, chuẩn hóa khoảng trắng, loại bỏ khoảng trắng thừa ở đầu và cuối chuỗi. Sau chuẩn hóa, nếu chuỗi ký tự của đoạn đầu vào và đoạn nguồn hoàn toàn giống nhau, hệ thống ghi nhận loại khớp Exact với điểm số 1.0.

Về mặt lý thuyết, Exact Matching có precision rất cao vì một đoạn văn dài trùng tuyệt đối gần như là bằng chứng trực tiếp của sao chép nguyên văn hoặc tái sử dụng nguyên văn. Tuy nhiên, recall của phương pháp này thấp hơn các phương pháp khác do chỉ cần thay đổi một vài ký tự, thêm dấu câu, đổi từ nối hoặc lỗi OCR/PDF extraction là hai chuỗi không còn bằng nhau tuyệt đối.

Vai trò của Exact Matching trong pipeline là cung cấp tín hiệu chắc chắn và tiết kiệm tài nguyên tính toán. Khi exact match được phát hiện, hệ thống có thể bỏ qua các bước N-gram và Fuzzy cho cặp đoạn đó, từ đó giảm số lần tính toán không cần thiết. Đây là lý do Exact Matching được đặt ở lớp đầu tiên trong thứ tự ưu tiên.

7.3. N-gram Overlap - phát hiện sao chép có chỉnh sửa nhẹ

N-gram là chuỗi gồm n đơn vị liên tiếp, trong hệ thống này đơn vị là từ. Với cấu hình 5-gram, một câu hoặc đoạn văn được biểu diễn thành tập các cụm 5 từ liên tiếp. Ví dụ, đoạn gồm các từ $w_1, w_2, w_3, w_4, w_5, w_6$ sẽ sinh ra hai shingles chính:

$(w_1, w_2, w_3, w_4, w_5)$ và $(w_2, w_3, w_4, w_5, w_6)$.

Cơ sở của N-gram Overlap là giả thuyết: nếu hai đoạn văn có nhiều cụm từ liên tiếp giống nhau, chúng có khả năng cao chia sẻ cùng nguồn diễn đạt bề mặt. Phương pháp này bền vững hơn Exact Matching vì đoạn văn vẫn có thể được phát hiện dù người viết thêm, xóa hoặc thay đổi một số từ cục bộ, miễn là phần lớn cụm 5 từ liên tiếp vẫn được bảo toàn.

Điểm số được tính theo hướng bao phủ một chiều đối với đoạn đầu vào:

$$\text{Overlap}(x, y) = \frac{|A \cap B|}{|A|}$$

Trong đó:

- A là tập 5-gram của đoạn input;
- B là tập 5-gram của đoạn source;
- $|A \cap B|$ là số 5-gram của input cũng xuất hiện trong source;
- $|A|$ là tổng số 5-gram của input.

Điều quan trọng là công thức này không dùng Jaccard đối xứng:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

mà dùng tỷ lệ bao phủ theo hướng input:

$$\frac{|A \cap B|}{|A|}$$

Lý do là trong Similarity Report, hệ thống quan tâm câu hỏi: bao nhiêu phần của bài upload bị match với nguồn? chứ không chỉ quan tâm hai đoạn giống nhau đối xứng đến mức nào.

Ví dụ, nếu input có 100 shingles và source chứa 95 shingles giống input, nhưng source dài hơn nhiều, thì:

$$\text{Overlap} = \frac{95}{100} = 0.95$$

Điều này phản ánh đúng rằng 95% đoạn input đã xuất hiện trong source.

Nếu dùng Jaccard, ta có:

$$J(A, B) = \frac{95}{|A \cup B|}$$

Khi source dài hơn rất nhiều, $|A \cup B|$ lớn, Jaccard có thể thấp hơn đáng kể, dù thực tế gần như toàn bộ đoạn input đã bị lấy từ source. Vì vậy, đối với bài toán Similarity Report, công thức lấy input làm mẫu số phù hợp hơn.

Điều kiện match bằng N-gram Overlap:

$$\text{match_type}(x, y) = \text{ngram} \quad \text{nếu} \quad \text{Overlap}(x, y) \geq \theta_{\text{ngram}}$$

Trong hệ thống:

$$\theta_{ngram} = 0.60$$

Tức là nếu ít nhất 60% 5-gram của đoạn input xuất hiện trong đoạn nguồn, hệ thống coi đây là một match có ý nghĩa.

N-gram Overlap phù hợp để bắt các trường hợp:

- copy dài nhưng sửa một số từ;
- copy đoạn rồi thêm bớt một vài câu;
- copy đoạn nhưng PDF extraction làm lệch ký tự hoặc xuống dòng;
- copy đoạn có thay đổi nhỏ về dấu câu, công thức, ký hiệu.

Ví dụ:

- Input:
The proposed method achieves high accuracy on the benchmark dataset.
- Source:
The proposed method achieves very high accuracy on the benchmark dataset.

Exact Matching sẽ không bắt được vì hai câu không giống hoàn toàn. Tuy nhiên, nhiều 5-gram vẫn trùng nhau, nên N-gram Overlap có thể phát hiện.

7.4. Fuzzy Matching và khoảng cách Levenshtein

Fuzzy Matching được sử dụng để phát hiện các đoạn có sự thay đổi nhỏ ở mức ký tự hoặc chuỗi. Trong hệ thống, kỹ thuật này được triển khai bằng RapidFuzz, dựa trên ý tưởng của Levenshtein ratio.

Khoảng cách Levenshtein giữa hai chuỗi là số thao tác tối thiểu cần thực hiện để biến chuỗi này thành chuỗi kia, gồm:

- thêm ký tự;
- xóa ký tự;
- thay thế ký tự.

Gọi a và b là hai chuỗi cần so sánh. Ma trận quy hoạch động D của khoảng cách Levenshtein được định nghĩa như sau:

$$D_{i,j} = \begin{cases} i, & j = 0 \\ j, & i = 0 \\ D_{i-1,j-1}, & a_i = b_j \\ 1 + \min(D_{i-1,j}, D_{i,j-1}, D_{i-1,j-1}), & a_i \neq b_j \end{cases}$$

Khoảng cách Levenshtein cuối cùng là:

$$d_{lev}(a, b) = D_{|a|, |b|}$$

Từ khoảng cách chỉnh sửa, hệ thống tính tỷ lệ tương đồng fuzzy như sau:

$$\text{Fuzzy}(a, b) = 1 - \frac{d_{lev}(a, b)}{\max(|a|, |b|)}$$

Giá trị fuzzy nằm trong khoảng:

$$\text{Fuzzy}(a, b) \in [0, 1]$$

Nếu hai đoạn giống hoàn toàn:

$$\text{Fuzzy}(a, b) = 1.0$$

Nếu hai đoạn khác nhau nhiều:

$$\text{Fuzzy}(a, b) \approx 0$$

Điều kiện match bằng Fuzzy Matching:

$$\text{match_type}(x, y) = \text{fuzzy} \quad \text{nếu} \quad \text{Fuzzy}(x, y) \geq \theta_{\text{fuzzy}}$$

Trong hệ thống:

$$\theta_{\text{fuzzy}} = 0.85$$

Tức là hai đoạn phải giống nhau ít nhất 85% theo fuzzy ratio mới được coi là match.

Fuzzy Matching phù hợp để bắt các trường hợp:

- sửa một số ký tự;
- lỗi OCR hoặc lỗi trích xuất PDF;
- thay đổi dấu câu;
- thay đổi một vài từ ngắn;
- xuống dòng hoặc khoảng trắng khác nhau.

Ví dụ:

Input:

The proposed method achieves 94.3 percent accuracy.

Source:

The proposed method achieves 94.3% accuracy.

Exact Matching có thể không bắt được vì khác ký hiệu % và từ percent. N-gram Overlap có thể giảm nếu câu ngắn. Fuzzy Matching vẫn có thể phát hiện vì phần lớn chuỗi vẫn giống nhau.

7.5. Cơ chế ưu tiên và tránh ghi nhận trùng lặp

Hệ thống áp dụng thứ tự ưu tiên Exact → N-gram Overlap → Fuzzy Matching. Thứ tự này dựa trên hai tiêu chí: độ chắc chắn của bằng chứng và chi phí tính toán. Exact có chi phí thấp và độ tin cậy cao nhất; N-gram có khả năng phát hiện chỉnh sửa nhẹ; Fuzzy có chi phí cao hơn nhưng xử lý tốt sai khác ký tự nhỏ.

Khi nhiều thuật toán cùng phát hiện một vùng văn bản tương đồng, hệ thống chỉ giữ nhãn khớp có mức ưu tiên cao hơn để tránh đếm lặp. Ví dụ, một đoạn đã được xác định exact match thì không cần ghi thêm cùng đoạn đó là n-gram match hoặc fuzzy match. Cơ chế này giúp báo cáo rõ ràng hơn và tránh thổi phồng số lượng matched passages.

Bên cạnh đó, các đoạn văn bản gần nhau hoặc chồng lấn vị trí có thể cùng trở về một vùng sao chép lớn. Nếu đếm từng match riêng lẻ, tổng số từ trùng khớp sẽ bị tăng sai. Vì vậy hệ thống sử dụng Interval Merging Algorithm để hợp nhất các khoảng vị trí bị chồng lấn hoặc liền kề, sau đó mới tính tổng số từ trùng khớp hợp lệ.

7.6. Ý nghĩa của passage-level matching trong báo cáo tương đồng

Ưu điểm quan trọng nhất của passage-level matching là tính giải thích được. Mỗi kết quả không chỉ có điểm số mà còn có thông tin nguồn đối chiếu, loại thuật toán phát hiện, đoạn văn bản nghi vấn, đoạn văn bản nguồn và phạm vi vị trí trong tài liệu. Điều này giúp người chấm hoặc chuyên gia thẩm định kiểm tra thủ công dễ dàng hơn.

Trong bối cảnh học thuật, một hệ thống phát hiện tương đồng không nên chỉ trả về kết luận 'đạo văn' hay 'không đạo văn'. Hai tài liệu có thể giống nhau do trích dẫn hợp lệ, do phần tài liệu tham khảo, do công thức toán học, do metadata hoặc do sử dụng các cụm thuật ngữ chuyên ngành bắt buộc. Vì vậy passage-level matching chỉ tạo ra bằng chứng tương đồng bề mặt; quyết định cuối cùng cần kết hợp với Citation & Exclusion Check và đánh giá ngữ cảnh.

Tóm lại, Exact Matching, N-gram Overlap và Fuzzy Matching tạo thành ba tầng đối soát bổ sung cho nhau. Exact đảm bảo phát hiện sao chép nguyên văn, N-gram phát hiện sao chép có chỉnh sửa nhẹ, còn Fuzzy xử lý sai khác ký tự nhỏ. Khi kết hợp với tiền lọc độ dài, kiểm tra tỷ lệ độ dài và gộp khoảng trùng, hệ thống tạo ra một lớp phân tích passage-level có khả năng vừa chính xác, vừa có thể giải thích trực quan trong báo cáo đầu ra.

8. CITATION & EXCLUSION CHECK

Module Citation & Exclusion Check đóng vai trò bộ lọc ngữ cảnh chuyên sâu, thực hiện phân loại trạng thái phân đoạn trùng khớp thành hai dạng chính: VALID (Đoạn trùng khớp hợp lệ đưa vào tính toán chỉ số tương đồng chính thức) và EXCLUDED (Đoạn trùng khớp bị loại trừ khỏi điểm số chính thức do các điều kiện học thuật hợp lệ, nhưng vẫn được hiển thị tường minh kèm lý do phân loại trên báo cáo).

Bộ lọc định nghĩa	Mục tiêu loại trừ ngữ cảnh	Giải thuật xử lý chi tiết
References Filter	Loại bỏ danh mục tài liệu tham khảo khỏi điểm số chính.	Nếu phân đoạn nằm trong phân vùng cấu trúc References hoặc có đặc điểm cấu trúc biểu mẫu của một reference entry (chứa mã số thứ tự, DOI, tên journal, năm xuất bản), hệ thống chuyển trạng thái EXCLUDED.
Quoted & Cited Filter	Khử nhiễu đối với các đoạn trích dẫn nguyên văn hợp lệ.	Kiểm tra đồng thời điều kiện: phân đoạn nằm trong dấu ngoặc kép trích dẫn đồng thời xuất hiện cấu trúc trích dẫn inline (inline citation) lân cận hoặc tài liệu nguồn hiện diện trong danh mục References của bài

Bộ lọc định nghĩa	Mục tiêu loại trừ ngữ cảnh	Giải thuật xử lý chi tiết
		viết.
Small Matches Filter	Loại trừ hiện tượng trùng hợp ngẫu nhiên các cụm từ thông dụng.	Tự động loại bỏ các phân đoạn trùng khớp có tổng số lượng từ nhỏ hơn 10 từ khởi trọng số tính điểm tương đồng chính thức.
Metadata / Boilerplate	Triệt tiêu siêu dữ liệu hành chính và mẫu văn bản hệ thống.	Sử dụng hệ thống danh sách mẫu (pattern list) nhận diện và loại trừ các chuỗi văn bản mẫu thông tin tác giả liên hệ, địa chỉ email, thông tin tài trợ nghiên cứu hoặc bản quyền nhà xuất bản.
Symbol-heavy Formula	Ngăn chặn hiện tượng lệch điểm số do trùng lặp biểu thức toán học.	Tính toán mật độ ký hiệu đặc thù (các ký tự không phải chữ cái, chữ số và khoảng trắng). Nếu mật độ ký hiệu vượt ngưỡng 45% đồng

Bộ lọc định nghĩa	Mục tiêu loại trừ ngữ cảnh	Giải thuật xử lý chi tiết
		thời phân đoạn ngắn dưới 80 từ, hệ thống tự động loại trừ.

8.1. Ký hiệu toán học cho một match

Gọi m là một match được phát hiện bởi lớp matching chi tiết. Để công thức gọn hơn, biểu diễn match m bằng các thuộc tính chính:

$$m = (t_i, t_s, id_s, sec, w, score)$$

Trong đó:

t_i : đoạn text trong tài liệu input.

t_s : đoạn text trong tài liệu nguồn.

id_s : mã nguồn hoặc paper ID của tài liệu nguồn.

sec : section của match, ví dụ body, introduction hoặc references.

w : số từ của match.

$score$: điểm match do Exact / N-gram / Fuzzy trả về.

Định nghĩa hàm loại trừ:

$$E(m) \in \{0,1\}$$

Trong đó:

$$E(m) = 1$$

nghĩa là match bị loại khỏi điểm similarity chính, còn:

$$E(m) = 0$$

nghĩa là match không bị loại.

Trạng thái hợp lệ được định nghĩa:

$$V(m) = 1 - E(m)$$

Do đó:

$$V(m) = \begin{cases} 1, & E(m) = 0 \\ 0, & E(m) = 1 \end{cases}$$

Ở đây, $V(m) = 1$ tương ứng với trạng thái **VALID**, còn $V(m) = 0$ tương ứng với trạng thái **EXCLUDED**.

8.2. Công thức tổng quát của Exclusion Check

Gọi các hàm điều kiện loại trừ như sau:

$R(m)$: match thuộc References hoặc giống reference entry.

$Q(m)$: match là quoted text và có citation hợp lệ.

$S(m)$: match quá ngắn.

$B(m)$: match thuộc metadata hoặc boilerplate.

$F(m)$: match là công thức ngắn nhiều ký hiệu.

Hàm loại trừ tổng quát:

$$E(m) = R(m) \vee Q(m) \vee S(m) \vee B(m) \vee F(m)$$

Nói cách khác, chỉ cần một trong các điều kiện loại trừ đúng thì match sẽ không được tính vào Overall Similarity.

Tập lý do loại trừ của một match được biểu diễn bởi:

$$L(m) = \{r \mid r \in \mathcal{R}, r(m) = 1\}$$

Trong đó:

$$\mathcal{R} = \{R, Q, S, B, F\}$$

Nếu $L(m)$ rỗng, match được xem là **VALID**. Nếu $L(m)$ khác rỗng, match được xem là **EXCLUDED**.

8.3. References / Bibliography Filter

Bộ lọc References / Bibliography nhằm loại bỏ các match xuất hiện trong phần tài liệu tham khảo. Trong bài báo khoa học, phần References thường chứa tiêu đề bài báo, tên tác giả, tên hội nghị, tên tạp chí, DOI hoặc ArXiv ID. Những thông tin này có thể trùng với nhiều nguồn nhưng không nên được tính vào similarity chính.

Hệ thống đánh dấu một match là reference-related nếu match thuộc section **references**, **bibliography**, hoặc nếu nội dung match có dạng giống một reference entry.

Ví dụ:

[12] A. Smith and B. Brown, Journal of Machine Learning Research, 2020.

Nếu đoạn này match với nguồn khác, hệ thống vẫn hiển thị trong report nhưng gán trạng thái **EXCLUDED** với lý do **reference_section** hoặc **reference_like_text**.

8.4. Quoted and Cited Text Filter

Một đoạn trích dẫn nguyên văn có thể giống hoàn toàn với nguồn, nhưng nếu nó

được đặt trong dấu ngoặc kép và có citation hợp lệ thì không nên bị tính mạnh vào điểm similarity chính. Vì vậy, hệ thống kiểm tra đồng thời hai yếu tố:

- Đoạn có phải quoted text không.
- Đoạn có citation gần đó hoặc nguồn có nằm trong References không.

Gọi $Qu(m)$ là hàm kiểm tra quote:

$$Qu(m) = \begin{cases} 1, & \text{nếu } t_i \text{ nằm trong dấu trích dẫn} \\ 0, & \text{ngược lại} \end{cases}$$

Gọi $C(m)$ là trạng thái citation:

$$C(m) = IC(m) \vee SC(m)$$

Trong đó:

$IC(m) = 1$ nếu đoạn input có inline citation dạng [1], [2,3], (Smith, 2020), (Smith et al., 2020).

$SC(m) = 1$ nếu nguồn match xuất hiện trong phần References của bài upload.

Khi đó:

$$Q(m) = Qu(m) \wedge C(m)$$

Nếu $Q(m) = 1$, match được loại khỏi điểm chính với lý do **quoted_and_cited**.

8.5. Small Match Filter

Các cụm quá ngắn thường không đủ mạnh để kết luận tương đồng có ý nghĩa. Trong văn bản học thuật, nhiều cụm như “in this paper”, “experimental results show”, “the proposed method” có thể xuất hiện ở rất nhiều bài báo.

Gọi $w(m)$ là số từ của match m . Bộ lọc small match được định nghĩa:

$$S(m) = \begin{cases} 1, & w(m) < \tau_s \\ 0, & w(m) \geq \tau_s \end{cases}$$

Trong hệ thống:

$$\tau_s = 10$$

Điều này có nghĩa là các match dưới 10 từ sẽ bị loại khỏi điểm similarity chính hoặc được đánh dấu là match nhỏ cần xem xét thủ công.

8.6. Metadata / Boilerplate Filter

Metadata và boilerplate là các thông tin lặp lại trong nhiều bài báo, nhưng không phản ánh nội dung học thuật chính

Các đoạn này có thể match rất cao, thậm chí exact match, nhưng nếu tính vào similarity chính thì điểm tổng sẽ bị nhiễu. Do đó, hệ thống sử dụng danh sách pattern để nhận diện metadata/boilerplate.

Công thức:

$$B(m) = \begin{cases} 1, & meta(t_i) = 1 \\ 0, & otherwise \end{cases}$$

Trong đó, $meta(t_i)$ trả về 1 nếu văn bản chứa các mẫu như:

corresponding author, email address, grant number, funded by, copyright, preprint submitted, keywords, arxiv header

Nếu $B(m) = 1$, match được đánh dấu **EXCLUDED** với lý do **metadata_or_boilerplate**.

8.7. Symbol-heavy Formula Filter

Các bài báo khoa học thường chứa nhiều công thức, ký hiệu toán học hoặc biểu thức bị trích xuất từ PDF dưới dạng text lỗi. Những đoạn này có thể match do cùng công thức hoặc cùng ký hiệu, nhưng nếu đoạn quá ngắn và chủ yếu là ký hiệu, nó không nên làm tăng mạnh Overall Similarity.

Hệ thống tính tỷ lệ ký hiệu của đoạn input:

$$\rho_{sym}(x) = \frac{N_{sym}(x)}{N_{char}(x)}$$

Trong đó:

$N_{sym}(x)$ là số ký tự không phải chữ cái, chữ số và không phải khoảng trắng.

$N_{char}(x)$ là tổng số ký tự của đoạn.

Bộ lọc formula-heavy được định nghĩa:

$$F(m) = \begin{cases} 1, & \rho_{sym}(t_i) \geq \theta_{sym} \wedge w(m) < \tau_f \\ 0, & otherwise \end{cases}$$

Trong hệ thống có thể chọn:

$$\theta_{sym} = 0.45$$

và:

$$\tau_f = 80$$

Điều này nghĩa là nếu một đoạn có trên 45% ký tự là ký hiệu và có dưới 80 từ, hệ thống sẽ đánh dấu là **symbol_heavy_short_formula**.

8.8. Citation Status

Ngoài việc loại trừ match, hệ thống còn gắn các trạng thái citation để hỗ trợ người chấm đánh giá ngữ cảnh. Mỗi match được bổ sung các trường:

- **source_cited**
- **inline_cited**
- **quoted**

- **excluded**
- **exclusion_reasons**
- **validity**

Ý nghĩa:

- **source_cited**: nguồn match có xuất hiện trong References hay không.
- **inline_cited**: đoạn input có citation gần đó hay không.
- **quoted**: đoạn input có nằm trong dấu trích dẫn hay không.
- **excluded**: match có bị loại khỏi điểm similarity chính hay không.
- **exclusion_reasons**: danh sách lý do loại trừ.
- **validity**: **VALID** hoặc **EXCLUDED**.

Trạng thái cuối của match:

$$Status(m) = \begin{cases} VALID, & E(m) = 0 \\ EXCLUDED, & E(m) = 1 \end{cases}$$

8.9. Tính Overall Similarity sau khi áp dụng bộ lọc

Điểm quan trọng nhất của module Citation & Exclusion Check là chỉ các match **VALID** mới được dùng để tính Overall Similarity. Các match **EXCLUDED** vẫn xuất hiện trong report nhưng không đóng góp vào số từ match hợp lệ.

Gọi M là tập tất cả match được phát hiện:

$$M = \{m_1, m_2, \dots, m_n\}$$

Tập match hợp lệ:

$$M_v = \{m \in M \mid E(m) = 0\}$$

Tập interval hợp lệ:

$$I_v = \{[s(m), e(m)] \mid m \in M_v\}$$

Sau đó, hệ thống gộp các interval chồng lấn để tránh cộng trùng:

$$I_v^* = Merge(I_v)$$

Số từ match hợp lệ:

$$VMW = \sum_{I \in I_v^*} w c(text[I])$$

Trong đó VMW là **ValidMatchedWords**. Cuối cùng:

$$OS = \frac{VMW}{TW} \times 100$$

Trong đó:

- OS là Overall Similarity.

- *VMW* là số từ thuộc các match hợp lệ sau khi gộp interval.
- *TW* là tổng số từ của tài liệu input sau khi làm sạch.

Nhờ cách tính này, các match thuộc References, quote hợp lệ, metadata hoặc small match sẽ không làm tăng Overall Similarity.

8.10. Hiện thị trong Similarity Report

Trong báo cáo HTML, mỗi match vẫn được hiển thị, kể cả khi bị loại trừ. Tuy nhiên, hệ thống phân biệt rõ:

```
Match#1      -      exact      -      score      1.000      -      VALID
Match#7      -      ngram      -      score      0.703      -      EXCLUDED
Reason: metadata_or_boilerplate
```

Báo cáo cũng có phần tổng hợp bộ lọc:

Thống kê	Ý nghĩa
Total Matches	Tổng số match phát hiện trước khi lọc.
Valid Matches	Số match được dùng để tính similarity chính.
Excluded Matches	Số match bị loại khỏi similarity chính.
Exclusion Reasons	Thống kê số lượng match theo từng lý do loại trừ.

Cách hiển thị này giúp hệ thống minh bạch hơn. Người chấm biết vì sao một đoạn không được tính vào điểm chính nhưng vẫn có thể kiểm tra lại nếu cần.

8.11. Kết luận

Module Citation & Exclusion Check là lớp kiểm soát ngữ cảnh quan trọng trong hệ thống. Sau khi Exact / N-gram / Fuzzy Matching phát hiện các đoạn tương đồng, module này quyết định match nào được tính vào điểm similarity chính và match nào chỉ nên hiển thị để tham khảo.

Nhờ đó, hệ thống tạo ra Similarity Report minh bạch hơn, giảm false positive và hỗ trợ người chấm đánh giá đạo văn theo ngữ cảnh thay vì chỉ dựa vào tỷ lệ giống văn bản thô.

9. ENGINE PHÁT HIỆN TƯƠNG ĐỒNG TRỰC TUYẾN (ONLINE RETRIEVAL)

Phân hệ xử lý trực tuyến được thiết kế theo cấu trúc pipeline liên hoàn tối ưu hóa, đảm bảo khả năng phản hồi kết quả báo cáo thời gian thực khi tiếp nhận một tài liệu nghiên cứu mới mà không yêu cầu khởi tạo lại cấu trúc chỉ mục hệ thống.

Bước thực thi	Mô tả chi tiết quy trình xử lý trực tuyến
Bước 1	Extract + Clean: Tiếp nhận tệp tin PDF đầu vào, kích hoạt giải mã trích xuất văn bản thô, áp dụng quy trình làm sạch tuần tự 9 tầng và thực hiện tách biệt phần văn bản tài liệu tham khảo.
Bước 2	Sectioning + Segmenting: Tự động bóc tách cấu trúc phần mở đầu, nội dung cốt lõi và tiến hành phân rã văn bản thành các phân đoạn paragraph độc lập phục vụ thuật toán.
Bước 3	MinHash Query: Khởi tạo chữ ký băm toán học cho văn bản đầu vào tuân thủ đồng bộ logic thiết lập tham số hệ thống ngoại tuyến.
Bước 4	Candidate Retrieval: Thực hiện truy vấn cấu trúc chỉ mục LSH Index nhằm xác định nhanh danh sách mã định danh các tài liệu nghi vấn từ kho dữ

Bước thực thi	Mô tả chi tiết quy trình xử lý trực tuyến
	liệu.
Bước 5	Gold Lookup: Thực hiện nạp chính xác phân vùng dữ liệu tối ưu trực tuyến từ tầng Gold dựa trên tiền tố mã hóa tài liệu về bộ nhớ đệm cục bộ.
Bước 6	Source Segmenting: Khởi tạo các phân đoạn văn bản nguồn đối chiếu từ dữ liệu ứng viên hoặc tiến hành nạp cấu trúc phân đoạn đã được thiết lập sẵn.
Bước 7	Detailed Text Matching: Thực thi chuỗi thuật toán so khớp đa tầng tuần tự Passage-level (Exact, N-gram Overlap và Fuzzy Matching) trên các cặp phân đoạn văn bản.
Bước 8	Citation & Exclusion Check: Áp dụng các bộ lọc đa ngữ cảnh phân loại và gắn nhãn trạng thái VALID hoặc EXCLUDED đi kèm hệ thống lý

Bước thực thi	Mô tả chi tiết quy trình xử lý trực tuyến
	do bóc tách chi tiết.
Bước 9	Scoring Calculation: Thực hiện thuật toán khử chồng lấn, xác định chỉ số Tương đồng Tổng thể, đo lường tỷ lệ đóng góp chi tiết của từng nguồn và phân loại mức cảnh báo rủi ro.
Bước 10	Report Generation: Kết xuất dữ liệu trực quan hóa cấu trúc thành tệp tin Báo cáo Tương đồng hoàn chỉnh hỗ trợ hiển thị chi tiết cho người sử dụng.

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ KỸ THUẬT

Kịch bản thực nghiệm hệ thống

Nhằm đánh giá một cách toàn diện và chính xác hiệu năng vận hành thực tế của pipeline trực tuyến mới, nhóm nghiên cứu đã triển khai phương pháp xây dựng một tập hợp các tệp tin PDF thử nghiệm đặc thù. Bộ dữ liệu kiểm thử này được khởi tạo bằng kỹ thuật cắt ghép, xáo trộn chủ ý các khối đoạn văn bản trích trích từ các bài báo khoa học hiện có trong kho cơ sở dữ liệu hệ thống. Quy trình đối soát trực tuyến được thực hiện thực nghiệm trên tập tệp tin này để tổng hợp dữ liệu định lượng đầu ra. Trong một kịch bản thử nghiệm tiêu biểu, lớp lọc thô LSH định vị chính xác và trả về thông tin của 3 tài liệu

ứng viên gốc bao gồm: arxiv_0704.0043.pdf, arxiv_0704.0071.pdf, và arxiv_0704.0082.pdf.

Định lượng và Đánh giá hiệu năng hệ thống

Hệ thống kết xuất dữ liệu báo cáo chi tiết trực quan hóa kết quả thực nghiệm với các chỉ số định lượng cụ thể:

Chỉ số định lượng	Giá trị thực nghiệm thu được	Ý nghĩa thực tiễn học thuật
Overall Similarity	91.23%	Tỷ lệ số lượng từ trùng khớp hợp lệ sau tiến trình loại bỏ nhiễu ngữ cảnh và gộp khoảng trùng.
Risk Level	Very High	Mức độ phân loại rủi ro học thuật ở phân cấp cao nhất, cảnh báo chuyên gia thẩm định cần xem xét chi tiết.
Matched Words Ratio	8012 / 8782 từ	Đo lường định lượng chính xác số từ nằm trong phân vùng khoảng trùng hợp lệ trên tổng số từ sạch.

Chỉ số định lượng	Giá trị thực nghiệm thu được	Ý nghĩa thực tiễn học thuật
Candidates Detected	3 tài liệu nguồn	Khối lượng các bài báo khoa học trong kho dữ liệu bị chỉ mục LSH định vị chính xác làm cơ sở đối chiếu.
Detail Matches Count	9 phân đoạn văn bản	Tổng số lượng các khối đoạn văn bản trùng khớp chi tiết được phân tích và ghi nhận thành công.
Primary Source Mapping	arxiv_0704.0043.pdf arxiv_0704.0071.pdf arxiv_0704.0082.pdf	Bản đồ lập chỉ mục định danh chi tiết danh sách hệ thống các tài liệu nguồn đối chiếu chính.

Phân tích sâu và Phản biện giải thuật kỹ thuật

Về mặt giải thuật lọc thô, việc LSH trả về khối lượng ứng viên cô đọng phản ánh chính xác đặc tính toán học của mô hình: hệ thống chỉ định vị và trích xuất các bài báo khoa học có xác suất tương đồng cú pháp bề mặt vượt ngưỡng thiết lập, thực hiện hoàn hảo vai trò giảm thiểu không gian tính toán. Đối với các kịch bản người dùng tải lên chính bài báo khoa học đã tồn tại trong kho hoặc các bản sao chỉnh sửa nhẹ, giải thuật định vị chính xác tài liệu nguồn mục tiêu duy nhất một cách hiệu quả.

Về mặt hạ tầng tra cứu trực tuyến, giải pháp thiết lập phân vùng bảng Gold Online

Lookup dựa trên tiền tố mã hóa tài liệu phối hợp với cơ chế lưu nhớ bộ đệm cục bộ đã giải quyết triệt để vấn đề nghẽn thời gian (bottleneck) khi scan trên bộ dữ liệu tích hợp Silver+ dung lượng lớn, chuyển hóa thành công hệ thống từ mô hình tính toán theo lô (batch/offline) sang phân hệ truy xuất thời gian thực trực tuyến siêu tốc.

Về phương thức tính toán điểm số tương đồng, việc hệ thống ưu tiên áp dụng các giải thuật đối soát văn bản bề mặt có khả năng giải thích tường minh từng phân đoạn (explainable passage-level matching) được khẳng định là phương án tối ưu cho bài toán Similarity Report, vượt trội so với việc sử dụng các mô hình học máy nhúng ngữ nghĩa (Semantic Embedding) kết hợp FAISS vốn chỉ cung cấp điểm số tương đồng vector tổng thể và không thể chỉ ra bằng chứng văn bản trùng khớp trực quan cho người sử dụng.

Hạn chế hiện tại và Định hướng phát triển tối ưu

Dù đạt được kết quả khả quan, hệ thống vẫn ghi nhận một số hạn chế cần nghiên cứu tối ưu:

1. Tối ưu hóa cấu trúc phân vùng trực tuyến: Kích thước một số phân vùng tiền tố dữ liệu hiện tại vẫn ở mức khá lớn. Hướng phát triển tiếp theo sẽ triển khai mô hình phân vùng sâu hơn dựa trên thuật toán băm phân thùng (pid_bucket) chi tiết.
2. Chuyển dịch tiến trình phân đoạn văn bản nguồn: Hiện tại việc bóc tách phân đoạn tài liệu ứng viên vẫn thực hiện trực tuyến. Hệ thống cần chuyển dịch công đoạn này sang luồng ngoại tuyến để khởi tạo sẵn kho lưu trữ Gold các phân đoạn văn bản sạch, triệt tiêu thời gian xử lý chuỗi khi online.
3. Nâng cấp bộ lọc trích dẫn chuyên sâu: Phương thức nhận diện trích dẫn hiện tại dựa trên các biểu thức chính quy cơ bản. Định hướng tiếp theo sẽ tích hợp các bộ công cụ trích xuất văn bản học thuật chuyên dụng để nhận diện toàn diện các chuẩn trích dẫn khoa học phức tạp như IEEE, APA, ACM hoặc các cấu trúc arXiv tham chiếu nâng cao.
4. Tinh chỉnh bộ lọc siêu dữ liệu: Tiếp tục cải tiến danh sách mẫu kiểm tra để nâng cao độ chính xác của bộ lọc boilerplate, ngăn chặn tuyệt đối rủi ro loại trừ nhầm các nội dung khoa học hợp lệ của bài viết.
5. Tích hợp giao diện người dùng trực quan: Phát triển hoàn chỉnh hệ thống API Backend nhận luồng dữ liệu PDF, kết hợp xây dựng giao diện ứng dụng Web giúp tự động highlight trực quan các phân đoạn văn bản tương đồng theo từng nguồn đối chiếu độc lập, tiệm cận hoàn toàn với cấu trúc vận hành của các hệ thống kiểm tra tương đồng thương mại quốc tế.